

Informe 1

Julio Agustín Tapia

PP: Análisis y Exploración de Datos

Instituto Superior de Formación Técnica N° 12

Año lectivo 2025


Desarrollo del informe:

CONSIGNA 1

1. Sección nominal: Elaborar un resumen de la cantidad de casos por enfermedad, por clasificación y por municipio. Elegí una variable que te interese y también incorpórala a tu resumen. Graficar.

Resumen de la actividad 1



Cantidad de casos por enfermedad:




Hallazgos: Podemos notar que, dentro de la base, luego de la limpieza que realicé, tenemos que el evento más común es el Intento de Suicidio, con un

65.6% de los casos, seguido por Coqueluche, con un 25,7% y luego tanto Lepra, como Hantavirosis compartiendo alrededor de 4% de los casos totales.


Cantidad de casos por Clasificación Manual:




Distribución de clasificación manual,
Hantavirus



Casos por clasificación manual, Lepra





Hallazgos:

Nuevamente podemos ver, que el evento más común es el Intento de Suicidio, pero ahora diferenciando por clasificación manual, queda a simple vista, que apenas un 2,7% de estos tiene resultado mortal.

Para lepra, se puede apreciar que tenemos 6 tipos de casos positivos, lo cuales todos aportan, ya que estos indican tanto el tipo de infección que les llevó a desarrollar la enfermedad, así como en qué estado continuaban al momento de recibir la consulta médica.

Para Hantavirosis, podemos observar que la mayoría de los casos que tenemos contabilizados, son positivos, y esto se debe al proceso de limpieza de la base de datos que realicé en los primeros pasos, por lo que la vista de este gráfico está sesgada a contabilizar solo aquellos casos positivos, así como aquellos que podrían haber sido positivos de tener seguimiento según el manual de normas.


En Coqueluche, podemos observar que un 67,4% de los casos son positivos, y eso es nuevamente debido al sesgo que tuve al momento de limpiar la base, por lo que contabilizamos solamente a los positivos y a aquellos que podrían haber resultado positivos de haber tenido seguimiento.



Cantidad de casos por Lugar de atención:

Antes de realizar el análisis, debo aclarar por qué decidí no utilizar la variable Localidad de residencia/Municipio para hacer el análisis.

La provincia de Buenos aires tiene 135 municipios, por lo cual graficar sobre esa cantidad enorme de categorías es un sinsentido, y hacer un top 10 hace que pierdas información al momento de mostrarla, por lo que me decanté por hacer una variable nueva, llamada Lugar de atención, en la cual puedo englobar cada región sanitaria donde se atendió la persona, así como en que provincia se atendió si es que la atención medica que la persona recibió no fue en la jurisdicción de PBA.

Ahora dicho esto, comenzamos mostrando los hallazgos.






Podemos observar que, en las personas dentro de nuestra base de datos, la gran mayoría decidió ir a atenderse dentro de la Provincia de Buenos Aires, siendo el segundo lugar más elegido para atenderse Ciudad Autónoma de Buenos Aires, por su cercanía.

Ya mirando lo que tenemos dentro de la provincia, podemos notar que la cantidad de eventos que recibe cada región sanitaria, se comportan más o menos dentro de lo esperado, debido a su población, siendo las dos más altas,

la Región Sanitaria XI, que corresponde al Partido de La Plata y alrededores, y la Región Sanitaria I, que corresponde Bahía Blanca y alrededores.

Cantidad de casos por “variable a elegir”:



Para mi variable a elegir, me decidí por ver qué porcentaje de los eventos que tenemos en la base, eligieron atenderse dentro de la provincia, esto debido a que me parece interesante poder ver quienes deciden atenderse fuera, ya sea por una razón u otra.

Observaciones:

Podemos notar, que el evento que más tiene mayor porcentaje de gente que se atendió fuera, fue la gente con Enfermedad de Hansen, que en específico, aquellos que no se atendieron en PBA, lo hicieron todos excepto 1, en CABA, mientras que 73 de los 94 intentos de suicidio que no se atendieron en PBA, también lo hicieron en CABA, y 71 de los 79 de Coqueluche, nuevamente, en CABA, lo que nos muestra por qué la cantidad de casos que se atendieron fuera de la provincia tienden a gravitar ahí, lo cual lo podemos relacionar con la distancia, (aunque cabe recordar SIEMPRE, que correlación NO implica causalidad).

CONSIGNA 2

Sección clínica 1)

Calcular la diferencia de días entre la fecha de inicio de síntomas y la fecha de consulta. Calculá la mediana de los días. ¿Qué significa esta información para cada enfermedad?

RESUMEN DE LA ACTIVIDAD 2

Calculamos la diferencia de días entre la fecha de inicio de síntomas, y podemos notar que hay eventos con mucha diferencia entre el inicio de los síntomas y la fecha de consulta, y casi todos estos se trataban de casos de Enfermedad de Hansen, y esto tiene sentido, debido a que los tratamientos suelen ser muy largos, así como la evolución de la enfermedad. En cambio a simple vista, para el resto de enfermedades, tenemos diferencias de días mucho más razonables, teniendo un promedio de 11.8 días entre la fecha de inicio y la fecha de consulta, siendo estirado este promedio hacia arriba por los casos de Lepra, y hacia abajo por la cantidad de 0 días que hay en la mayoría de los eventos.

Hablando de 0, sigamos con la mediana, tanto la mediana como la moda, para la diferencia que hicimos, el valor es 0, ya que es de lejos el valor que más se repite, y esto puede deberse a varias cosas, por ejemplo, en los casos de intento de suicidio con resultado mortal, es imposible saber a ciencia cierta cuando la persona empezó a tener síntomas de tener intenciones de quitarse la vida. (aunque esto ya es una especulación mía, y sale del ámbito del análisis de los datos)

Para responder con claridad esta pregunta: ¿Qué significa esta información para cada enfermedad?

Lepra:

La mediana para la lepra, como pudimos observar dentro de la base de datos, si bien la mediana es 0, es bastante probable que la diferencia sea alta, ya que los síntomas iniciales son leves, lentos y muchas veces no se perciben de forma fácil. Lo que lleva a que pueda/haya un retraso considerable en la consulta.

Hantavirosis:

La mediana para hantavirus, puede ser entre moderada y alta, porque los síntomas iniciales son inespecíficos, lo que puede retrasar la consulta y el diagnóstico.

Intento de suicidio: La mediana puede ser 0 o muy cercana a 0, ya que el evento es repentino, y esta no debe ser tomada como un indicador de evolución de síntomas sino de la imposibilidad de determinar retrospectivamente cuando comenzaron los pensamientos o conductas suicidas, esto nos refleja mas una limitación en el registro de datos que un retraso en la consulta.


CONSIGNA 3

Sección clínica 2


¿Cuál es el síntoma que más se repite en cada enfermedad?

¿Cuántos de los casos fueron internados y/o fallecieron?

RESUMEN DE LA ACTIVIDAD 3




Ocurrencia de Síntomas, Hantavirosis






Ocurrencia de Síntomas, Intento de suicidio

- Bajo efectos de sust. psicoactiva
- Establecimiento de salud
- Establecimiento educativo
- Institución residencial
- Lugar de ocurrencia: Vía pública
- Lugar de ocurrencia: Vivienda
- Lugar de trabajo
- Mecanismo: Ahogamiento por sumersión
- Mecanismo: Ahorcamiento, estrangulamiento o sofocación
- Mecanismo: Arrojarse o colocarse delante de objeto en mov.
- Mecanismo: Disparo de armas de fuego
- Mecanismo: Objeto cortante
- Mecanismo: Saltar desde un lugar elevado
- Mecanismo: Siniestro vial
- Mecanismo: Sobreingesta de medicamentos
- Otro lugar de ocurrencia del evento
- Otro mecanismo o modalidad



Ocurrencia desíntomas, Lepra





Observaciones:

Comenzando por los internados y fallecidos por evento, podemos ver, que para ambas categorías, el evento que prima es el Intento de suicidio, lo cual muestra su mayor severidad en comparación a los otros eventos que tenemos para analizar. También podemos ver que, dentro de nuestro recorte, ninguno de los casos de lepra tuvo resultado mortal.

Observando los gráficos de síntomas por evento podemos notar que, Coqueluche es la enfermedad con menor cantidad de síntomas, y que dos de los síntomas más recurrentes son, la tos paroxística, y la tos por más de 14 días, lo cual es de esperar, ya que Coqueluche también es conocido como Tos convulsa.

Con hantaviriosis, se puede ver que los síntomas son muy diversos, así como que los que más ocurrencia tienen, son síntomas inespecíficos, lo cual puede retrasar el diagnóstico, y siendo el más ocurrente, la Fiebre alta, o $>38.5^{\circ}$.

Con Lepra, Se puede ver que el síntoma más recurrente es el compromiso de piel.


Con intentos de suicidio, podemos ver, que el “síntoma”, que en este caso sería el mecanismo más utilizado es la Sobre ingesta de medicamentos y el lugar más común, es en la vivienda.

CONSIGNA 4

Sección de laboratorio:

¿Qué porcentaje de casos dieron negativo al estudio de laboratorio? ¿Qué porcentaje representan los casos de los cuales no se posee ningún tipo de información?

RESUMEN DE LA ACTIVIDAD 4:



Observaciones:

Podemos ver que, en la gran mayoría de casos, no tenemos resultados de laboratorio, y en nuestro recorte, los casos donde no tenemos información representan un 77% de los eventos, mientras que los positivos un 18,6% y los negativos un 4,4%.



Hay que tener en cuenta, que estos resultados están sesgados, debido al proceso que utilicé para limpiar la base, por lo que los resultados pueden variar.


CONSIGNA 5

Sección Epidemiología:

Elaborar una tabla con la cantidad de casos y los antecedentes epidemiológicos por municipio y por enfermedad. Graficar con columnas.

RESUMEN DE LA ACTIVIDAD 5:





Observaciones:

Podemos notar que, en los gráficos de arriba, está ausente el gráfico de antecedentes en Intentos de Suicidio, y esto no es casualidad, ya que incluso en la base sin filtrar, este evento no posee cargado ningún tipo de antecedentes epidemiológicos cargados.

Siguiendo con los eventos que, si podemos ver, con coqueluche, independientemente de en que lugar de atención se encuentre, el antecedente epidemiológico más común es el Contacto con una persona con tos persistente, en lepra, el antecedente más común es el viaje a una zona endémica, y en hantavirosis, el antecedente más común es contacto con roedores silvestres, su orina o deposiciones, esto parece comportamiento esperado, (según mi sesgo).

CONSIGNA 6

¿Encontrás algún dato que te haga sospechar que pueda tratarse de un error del operador al momento de la carga?

RESUMEN DE LA ACTIVIDAD 6:

Sí, en el caso de la base que recibimos, (que estaba sucia a propósito) me llama la atención variables como por ejemplo Sexo Legal, que de forma usual es información automática que ya proviene del RENAPER, y que de acuerdo a la Ley de Identidad de Género, deberíamos de poder tener 3 valores posibles: "X", "M", "F", por lo que el valor "A" en caso de saber que esta variable no es de llenado automático, me haría sospechar que hay un error de carga.

Otro dato que me haría sospechar de un error de carga, sería por ejemplo una diferencia enorme de la cantidad de días entre el inicio de síntomas y la fecha de consulta, para otros eventos que no sean Lepra, por ejemplo Coqueluche, con inicio hace 2 años y consulta en 2025 salta a la vista como un error de carga (o un outlier muy, muy, muy exótico).

Como ultima variable, voy a tomar como algo que me salta a la vista un posible error de carga, es la localidad de residencia, ya que la misma debe ser cargada en un evento nominal, y no debería contener valores nulos.

Sección de feedback y aportes de compañeros.

La totalidad de los aportes que tuve en cuenta, mas que nada porque fue con la única persona con la que pude tener discusiones sobre como realizar el informe, fue con el alumno Maximiliano Benet, que si bien, no se tiene registro en los foros de que me haya hecho aportes, estuvo atento a lo que yo subía a los foros y luego en las discusiones presenciales, salían ideas nuevas para poder encarar la consigna.

Uno de los cambios que surgieron gracias a el fue el de ordenar primero el csv antes de eliminar duplicados, ya que como lo venía encarando el era solo quitar duplicados manteniendo la primera instancia en Python, por lo que me hizo dudar y terminé optando por organizarlos primero.

Otra cuestión, que surgió, fue de como normalizar las localidades de los eventos que teníamos, antes de dicha discusión, lo que yo planteaba hacer era

agarrar las localidades y mandar todo por región sanitaria y ya está, y mostrándome la normalización que había hecho por municipios, me dio la idea de normalizar, sí, pero por establecimientos, lo cual me llevó a poder ver los casos que habían recibido atención fuera de la provincia.

Lamentablemente no pude tomar aportes desde el foro, en parte por los recientes cortes y el mal funcionamiento del mismo, pero los aportes en discusiones verbales me ayudaron mucho a poder guiar por donde iba a encarar el análisis.